Datos, estimando y método

Prototipo «Puente» — semana 4 · escenario `synthetic/ihdp` · documento de referencia del benchmark sintético, del estimando y del prototipo en producción local.

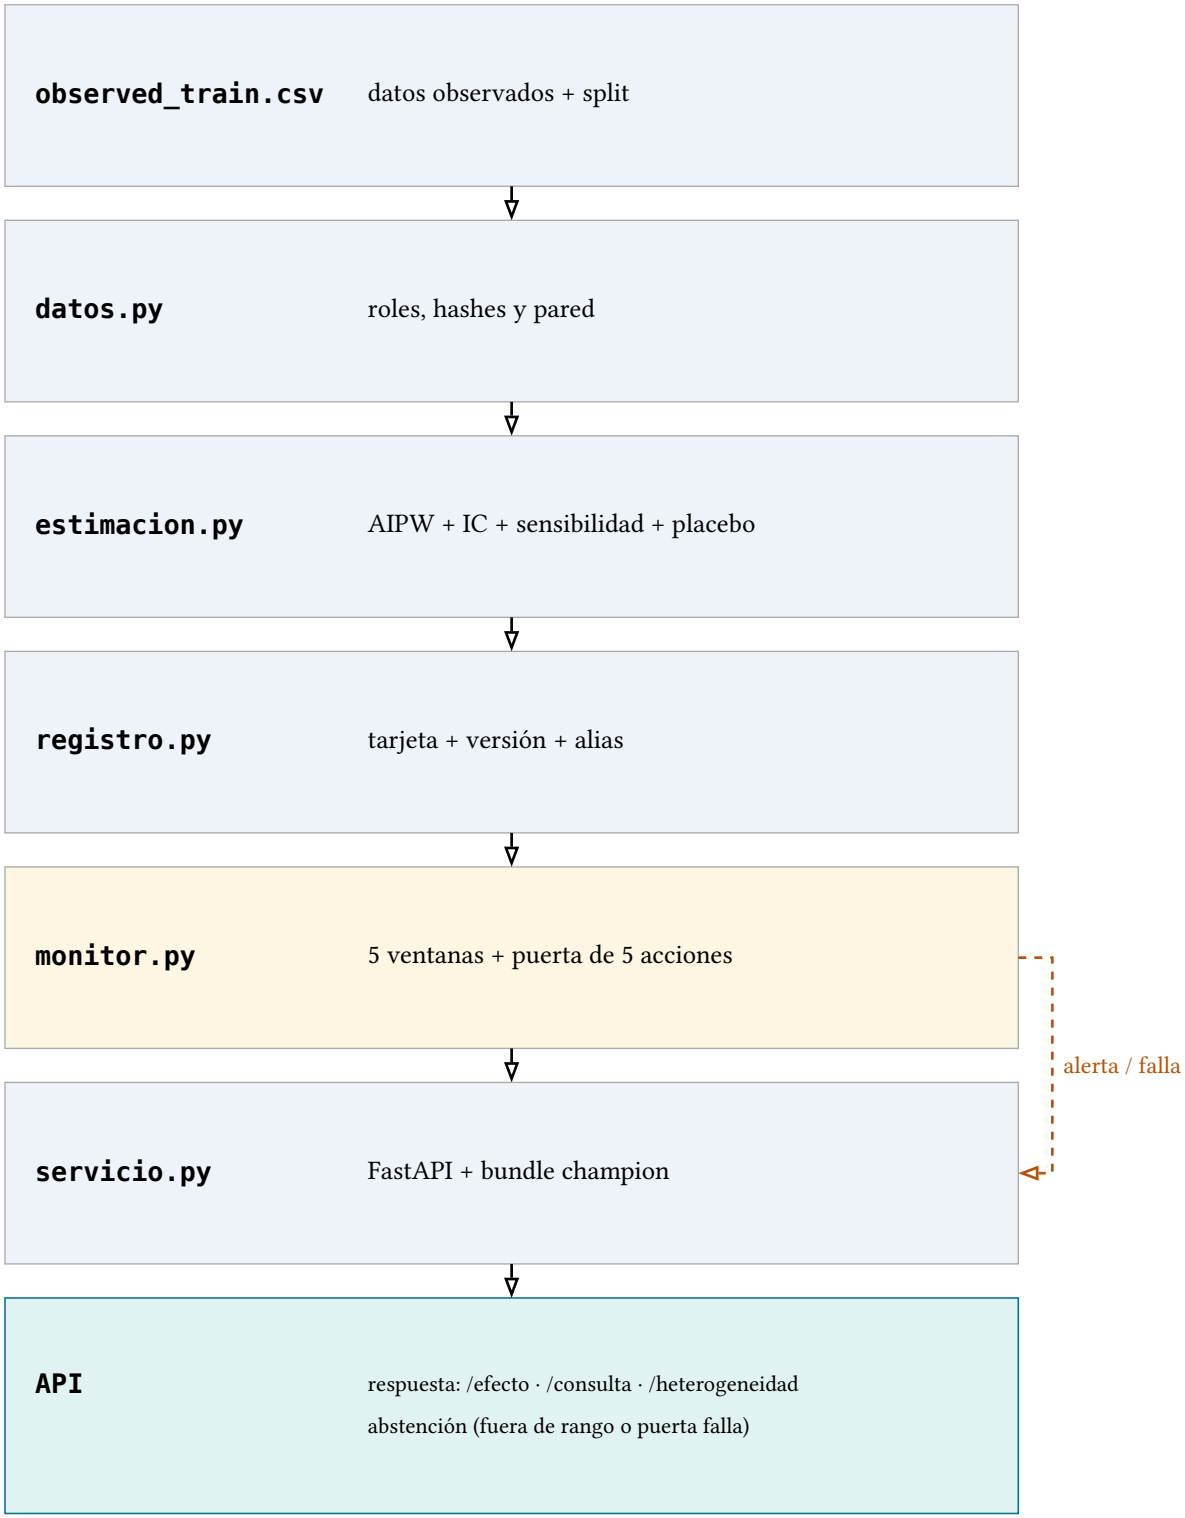


Figura 1: **Flujo del trabajo.** Cada etapa consume los artefactos de la anterior. Azul: pipeline; ámbar: puerta; verde: servicio. La flecha discontinua indica que `alerta` o `falla` detiene el despliegue.

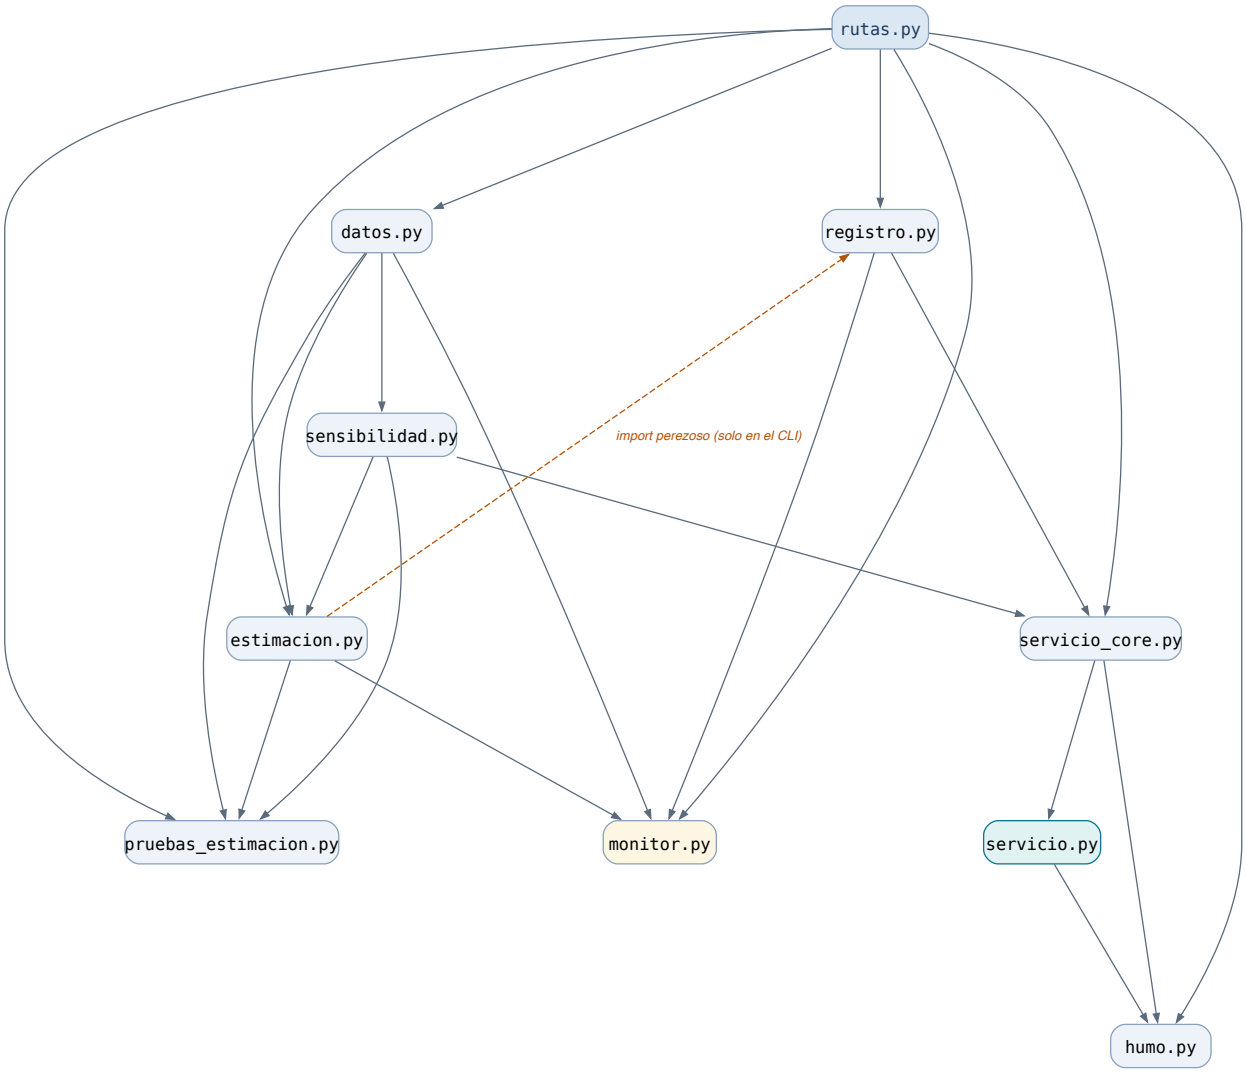


Figura 2: **Dependencias entre módulos.** La flecha va del módulo importado al que importa: `A -> B` significa que `B` hace `import A`. Azul: configuración común; ámbar: el monitor; verde: el servicio. La flecha discontinua es el import perezoso de `registro.py`, que solo ocurre al ejecutarlo como programa.

Tres cosas que el dibujo no deja ver.

- **Ningún módulo orquesta a los demás.** El orden del pipeline no está en Python: está en el `Makefile` (`make demo`). Cada etapa es un proceso aparte que lee los JSON de la anterior y escribe los suyos.
- **`monitor.py` importa el código de estimación**, no solo su JSON (`aipw_crossfit`, `propensity`, `smd`). Reutilizar el monitor arrastra `estimacion.py` y, con él, `scipy`.
- **El import de `registro.py` es perezoso a propósito.** Vive dentro de `if __name__ == "__main__":`, no en la cabecera. Como `servicio_core.py` importa `registro`, un import de nivel superior haría que levantar la API cargara `numpy` y `scipy` sin necesidad.

`rutas.py` es la hoja del grafo y el único punto de configuración: rutas, escenario y `SIC_ESCENARIO`.

Alcance. `synthetic/ihdp` y `synthetic/jobs` son nombres de escenario; todos los valores son sintéticos. Los resultados son una demostración metodológica, no una recomendación clínica, laboral o de política pública. El caso es uno de los casos guiados del curso: el subcriterio 1.1 queda en parcial y no se presenta como trabajo final autónomo.

1. Escenarios y archivos

Dato	`synthetic/ihdp`	`synthetic/jobs`
Inspiración	Hill (2011), JCGS 20(1)	LaLonde (1986), AER 76(4)
Unidades (total; train / validation / test)	747 (448 / 149 / 150)	1722 (1033 / 344 / 345)
Covariables	25 continuas (`bw` … `was`)	8 (`age` … `re75`)
Tratados (train)	191 (42,7 %)	262 (25,4 %)
Resultado	`outcome`: puntaje cognitivo a 3,5 años	`re78`: ingresos de 1978 (USD)
Escala del resultado	puntos	dólares de 1978

Cada carpeta contiene:

- `observed.csv`, el conjunto completo, y `observed_train.csv`, `observed_validation.csv` y `observed_test.csv`, las particiones 60/20/20 generadas con semilla `20240701`. `splits.json` registra tamaños y hashes SHA-256; `datos.py` los recalcula.
- `metadata.json` describe el escenario; `identification.json` declara el conjunto de ajuste válido según el diseño del benchmark. Es una anotación del benchmark, no una prueba independiente de identificación causal.
- `interventions.json` incluye referencias agregadas (`ate`, `att` y resumen de `tau`). Se reserva para la comparación final: no se consulta para estimar ni calibrar.
- No se incluyen columnas observadas de resultados potenciales ni archivos `truth_*.csv`. No hay verdad causal individual disponible para el análisis unidad por unidad.

Datos y autorización. El paquete es sintético y no contiene registros personales; no requiere autorización. Si se usara un caso propio, habría que declarar la autorización y mantener los datos fuera del paquete. El hash de `observed_train.csv` viaja en `artifacts/estimacion.json` y en el manifiesto de la versión registrada.

1.1 Origen del dato: tres capas que no conviene confundir

«IHDP» nombra a la vez un ensayo clínico, un benchmark semi-sintético construido a partir de él y, en este paquete, un escenario sintético inspirado en ambos. Confundir las capas es el error más frecuente al citar este dataset: cambia el tamaño muestral, el desbalance entre brazos y hasta la identificabilidad del estimando.

Capa 1 — el ensayo real. El *Infant Health and Development Program* fue un ensayo aleatorizado multicéntrico en 8 hospitales universitarios de EE. UU., financiado por la Robert Wood Johnson Foundation, con reclutamiento entre noviembre de 1984 y agosto de 1985 e intervención entre 1985 y 1988. Se eligieron lactantes con peso al nacer de 2.500 g o menos y 37 semanas de gestación o menos. De 4.551 nacidos, 1.302 fueron elegibles y 985 se aletorizaron: **377 al brazo de intervención y 608 al de seguimiento**. La intervención combinó visitas domiciliares (semanales el primer año, quincenales después), un centro de desarrollo infantil a tiempo completo entre los 12 y los 36 meses, y grupos de apoyo para padres. El resultado primario fue el **CI de Stanford–Binet a los 36 meses**; el ensayo reportó una ganancia media cercana a 9 puntos, con 13,2 en el estrato de mayor peso y 6,6 en el de menor, que se atenuó a los 5 y a los 8 años.

Capa 2 — el benchmark de Hill (2011). Hill conservó las *covariables reales* y la *asignación de tratamiento del ensayo*, y sustituyó los resultados por simulaciones. Para inducir confusión eliminó a todos los tratados cuya madre no era blanca, lo que deja **139 tratados y 608 controles (747 unidades)**. El precio de ese filtrado es alto: destruye el solapamiento, de modo que en el benchmark canónico el estimando defendible es el ATT o

el CATT, no el ATE. Las 25 covariables son 6 continuas —peso al nacer, perímetro cefálico, prematurez, orden de nacimiento, índice de salud neonatal y edad de la madre— y 19 binarias, siete de ellas dummies de centro. La superficie de respuesta habitual («Setting B») es no lineal y no paralela: el potencial bajo control se genera como exponencial de una combinación lineal, y el efecto sobre los tratados se calibra en 4.

Capa 3 — este paquete. `synthetic/ihdp` **no contiene ningún registro del ensayo**. `metadata.json` lo declara sin ambigüedad: `SYNTHETIC - generated from scratch using formula-based simulation (Hill 2011 style)`. Se conservan el nombre del escenario, el número de unidades (747), el número y los nombres de las covariables y el orden de magnitud del efecto de referencia. Todo lo demás —covariables, tratamiento y resultado— se simula: covariables de distribución normal estándar, tratamiento por un modelo logístico en `X` y resultado lineal con efectos heterogéneos, con semilla de generación 400. La partición 60/20/20 usa otra semilla, 20240701, y es estratificada por tratamiento.

Rasgo	**`synthetic/ihdp`**
Unidades	747 en total: 448 en `train`, 149 en `validation`, 150 en `test`
Covariables	25, todas continuas y simuladas
Tratamiento: columna `treatment`	binaria 0/1: 1 = programa de intervención temprana (visitas domiciliares, centro infantil a tiempo completo y grupos de padres, del alta a los 36 meses); 319 tratados de 747 (42,7 %)
Resultado: columna `outcome`	puntaje cognitivo a los 3,5 años, en puntos; mayor es mejor
Efecto de referencia	ATE 3,92 y ATT 4,15 en `interventions.json`

Nota. El escenario es sintético: sirve para validar la cadena —estimador, diagnósticos, puerta, registro y servicio —, no para concluir nada sobre el programa.

Fuentes. Hill, J. L. (2011). Bayesian Nonparametric Modeling for Causal Inference. *Journal of Computational and Graphical Statistics* 20(1), 217–240. doi:10.1198/jcgs.2010.08162. Infant Health and Development Program (1990). Enhancing the outcomes of low-birth-weight, premature infants: a multisite, randomized trial. *JAMA* 263(22), 3035–3042. Brooks-Gunn y cols. (1994), *JAMA* 272(16), 1257–1262. Para el uso del benchmark en aprendizaje automático causal: Shalit, Johansson y Sontag (2017), *PMLR* 70, 3076–3085; Curth y cols. (2021), *NeurIPS Datasets and Benchmarks*.

1.2 Anatomía de los datos: covariables, tratamiento y resultado

El escenario tiene 747 filas y 27 columnas: 25 covariables pre-tratamiento, una columna de tratamiento y una de resultado. Las covariables llevan nombre clínico, pero aquí son normales estándar simuladas: el nombre indica qué papel juega la variable en el diseño, no una medición.

Las 25 covariables, por bloque. La agrupación es semántica, no de tipo: en este escenario las 25 son continuas, así que no hay indicadores binarios ni dummies de centro en sentido estricto.

Bloque	**Variables**	**Por qué se ajusta por ellas**
Neonatal (5)	`bw`, `b.head`, `preterm`, `birth.o`, `nnhealth`	Determinan quién entra al programa y predicen el desarrollo cognitivo
Del niño (2)	`sex`, `twin`	Moderadores del desarrollo; entran en el modelo de tratamiento
Materno (6)	`momage`, `prenatal`, `cig`, `booze`, `drugs`, `first`	Conducta y cuidado prenatal: afectan al tratamiento y al resultado
Socioeconómico (5)	`mom.lths`, `mom.hs`, `mom.scoll`, `b.marr`, `work.dur`	Estrato social: selecciona al tratamiento y condiciona el resultado
Sitio (7)	`ark`, `ein`, `har`, `mia`, `pen`, `tex`, `was`	Centro de reclutamiento: práctica clínica distinta en cada sede

La suma cuadra: cinco bloques, veinticinco variables, ninguna fuera de un bloque.

El tratamiento es la columna `treatment`. Vale 1 si la unidad recibió el programa de intervención temprana —visitas domiciliares, centro infantil a tiempo completo y grupos de padres, del alta a los 36 meses— y 0 si solo recibió seguimiento. Es binaria, fija en el tiempo y de una sola versión, como exige SUTVA. Hay 319 tratados de 747 (42,7 %), y 191 de 448 en `train` (42,6 %). Aquí el programa es solo la etiqueta del brazo: la columna se genera con un modelo logístico en `X`, sin simular visitas ni dosis.

El resultado es la columna `outcome`. Es el puntaje cognitivo a los 3,5 años: continuo, medido una sola vez después del tratamiento y en el que mayor es mejor. En `train` la media es 46,6 en control y 57,0 en tratados. Sobre una desviación típica de 15,0 puntos, el efecto de 5,2 equivale a 0,34 desviaciones típicas: una magnitud pequeña-media.

La brecha de confusión. El contraste bruto mezcla efecto y composición:

Cantidad	Valor	Lectura
Diferencia cruda de medias	10,3; IC aprox. [7,60; 13,05]	lo que se ve sin ajustar
OLS con las 25 covariables	4,8; IC [3,8; 5,8]	el mismo contraste, ajustado linealmente
AIPW con cross-fitting	**5,2; IC [3,9; 6,4]**	estimando principal (sección 6)
Atribuible a composición	≈ 5,2	cerca de la mitad del contraste bruto

Quién es confusor. Las 25 covariables lo son **por construcción**: cada una es causa del tratamiento y del resultado. La pregunta no es «¿ajusté por lo correcto?» —eso lo fija el diseño— sino «¿la maquinaria corrige una confusión que sé que existe?». El residuo se mide con propensiones OOF antes del `trimming`: el SMD máximo cae de 0,43 sin ponderar a 0,11 ponderado por IPW, y el ESS de Kish es 332,2076 de 448 (0,7415; ≈332/448 y 0,74).

2. Pregunta, estimando y población

> **Pregunta de decisión.** ¿Debe ampliarse el programa de intervención temprana a la población del estudio para mejorar el puntaje cognitivo a los 3,5 años?

El estimando declarado antes de mirar los efectos es el **efecto promedio del tratamiento** (ATE):

$$\tau = E[Y(1) - Y(0)]$$

- **Unidad:** puntos del test cognitivo en `synthetic/ihdp`; dólares de 1978 en `synthetic/jobs`.
- **Población objetivo:** las 448 unidades de `observed_train.csv` en `synthetic/ihdp`. El AIPW promedia scores sobre esta muestra; la interpretación causal requiere los supuestos de la sección 4.
- **Qué cubre el IC del ATE:** incertidumbre del efecto promedio, no un efecto individual ni un CATE. `/consulta` devuelve, como máximo, la media de un estrato predefinido; tampoco es un efecto individual.
- **No es el ATT.** Preguntar por el efecto «en quienes recibieron el programa» describe el ATT. En la referencia agregada de `synthetic/ihdp`, ATE = 3,92 y ATT = 4,15; se comparan solo al final.

3. Identificación y por qué el ATE es identificable

La estrategia es **ajuste por covariables observadas (backdoor)**: las 25 covariables pre-tratamiento bloquean los caminos traseros entre `D` y `Y`. Es la estrategia natural porque el benchmark es un corte transversal sintético, `metadata.json` declara que el tratamiento se genera con un modelo logístico en `X` y el resultado con fórmulas lineales en `X`, `D` y ruido, y `identification.json` lista las 25 covariables como conjunto de ajuste válido. No se usa variable instrumental, diferencias en diferencias ni regresión discontinua: no hay instrumento, panel pre/post ni umbral de asignación.

Comprobación ejecutable. `identificacion_dowhy()` construye el DAG y ejecuta DoWhy con `method_name="default"`, que aplica el criterio **backdoor** y devuelve el conjunto de ajuste. En el champion, `identificacion_pasa = true`: el conjunto contiene las 25 covariables y coincide con `valid_adjustment_sets`.

`id-algorithm` aporta una expresión algebraica complementaria, no una segunda prueba. `/efecto` y `/salud` informan `criterio = backdoor` y `pasa = true`.

Supuestos de identificación.

- **A1. Ignorabilidad condicional:** $Y(0), Y(1)$ independientes de D dado X.
- **A2. Positividad:** $0 < e(X) < 1$ para todo X en la población objetivo.
- **A3. Consistencia / SUTVA:** $Y = Y(D)$ y no hay interferencia.

Con A1–A3:

$$E[Y(1)] = E_{X[E[Y(1) \mid X]]} = E_{X[E[Y(1) \mid X, D=1]]} = E_{X[E[Y \mid X, D=1]]}$$

$$E[Y(0)] = E_{X[E[Y(0) \mid X]]} = E_{X[E[Y(0) \mid X, D=0]]} = E_{X[E[Y \mid X, D=0]]}$$

Por tanto:

$$\tau = E_{X[E[Y \mid X, D=1] - E[Y \mid X, D=0]]}$$

El AIPW es un análogo muestral de ese funcional:

$$\psi_i = \hat{\mu}_1(X_i) - \hat{\mu}_0(X_i) + \frac{D_i(Y_i - \hat{\mu}_1(X_i))}{\hat{e}(X_i)} - \frac{(1 - D_i)(Y_i - \hat{\mu}_0(X_i))}{1 - \hat{e}(X_i)}$$

$$\hat{\tau} = \frac{1}{n}\sum_{i=1}^{n} \psi_i, \quad \hat{\text{se}} = \frac{\text{sd}(\psi)}{\sqrt{n}}$$

La identificabilidad es una propiedad del modelo causal y de A1–A3, no del estimador. El AIPW es consistente bajo regularidad y especificación correcta de al menos uno de los dos modelos auxiliares. La referencia del DGP (ATE ≈ 3,92) no interviene en la prueba ni en la estimación.

Por qué A2 no es un adorno. En el benchmark canónico de Hill el filtrado elimina a todos los tratados con madre no blanca: en ese estrato no queda ninguna unidad tratada, la positividad falla y el ATE deja de estar identificado. En este paquete el DGP no borra unidades tratadas —solo simula un tratamiento logístico en `X`—, así que A2 se sostiene sobre `train` y el ATE es identificable. La diferencia es del escenario, no del estimador (sección 1.1).

Límite. `identification.json` es una anotación del benchmark. En datos reales la ignorabilidad no se verifica con los datos; se defiende o se acota. El DAG completo de la sección 14 explicita la amenaza de confusión no medida.

4. Supuestos: validez, evidencia y límites

Supuesto (formal)	Clase	Evidencia, tratamiento y límite
Ignorabilidad condicional: $Y(0), Y(1)$ independientes de D dado X	`no_observable`	El DGP simula el tratamiento con un logístico en `X` y el resultado con fórmulas lineales en `X`, `D` y ruido; no hay confusor latente simulado. Se chequea con balance, placebo de tratamiento y placebo de resultado. No se verifica con los datos observados ni se generaliza a IHDP real.
Positividad / soporte común: $0 < e(X) < 1$	`observable`	En `train`, las propensiones estimadas fuera de pliegue (OOF), antes del `trimming`, tienen rango [0,043; 0,916] y solape 0,99777 en [0,05; 0,95] (≈99,8 %; la CLI redondea 100 %). El ESS de Kish es 332,2076/448 = 0,7415 (≈332/448 y 0,74). Se recorta 1 unidad de 448 (0,2232 %); todos los recortes son controles (1/257 = 0,3891 % de controles) y ninguno es tratado. Son diagnósticos muestrales; no prueban positividad poblacional ni para perfiles nuevos. El servicio se abstiene fuera del rango de entrenamiento.

Supuesto (formal)	Clase	Evidencia, tratamiento y límite
Consistencia / SUTVA: $Y = Y(D)$ y no interferencia	`no_observable`	El DGP es unitario, con ruido independiente. No hay chequeo directo; se declara la limitación. En un programa real puede haber spillovers, equilibrio general o versiones distintas de implementación.
Covariables medidas antes del tratamiento	`observable`	`metadata.json` e `identification.json` lo declaran. `score_post` es una columna construida con `Y` para demostrar fuga de información: no es una covariable real ni un placebo.

Clasificación y evidencia falsificable. La tarjeta (`tarjeta.json`) y el código del kit clasifican cada supuesto como `observable` o `no_observable`. En la guía del curso, **falsificable** nombra el tratamiento de la evidencia (placebos, diagnósticos de soporte, sensibilidad): aquí está en §5–§8 y en `evidencia/`. La tabla anterior enlaza cada supuesto con su clase en tarjeta y con lo que se hizo para contrastarlo, sin presentar la ignorabilidad como un hecho verificado por los datos.

Nota sobre `score_post`. La trampa vacía el coeficiente del tratamiento (ATE ≈ −0,1) porque introduce el resultado en el ajuste. Es una prueba de fuga de información, no un control negativo. El placebo real se describe en la sección
5.

5. Sensibilidad y placebo

Medida	Resultado	Lectura y límite
E-value (aprox. continuo)	2,07; IC 1,85	Un confusor no medido tendría que asociarse con `D` y `Y`, condicionando en `X`, con una RR aproximada de al menos 2,07 para explicar el efecto puntual; el límite del IC exige 1,85. Es una aproximación vía efecto estandarizado; no es una RR literal ni una cota exacta.
Valor de robustez (Cinelli–Hazlett)	37,4 %	Un confusor no medido tendría que explicar al menos el 37,4 % del R^2 parcial de `D` y de `Y`, después de condicionar en `X`, para llevar el coeficiente OLS a cero. Es exacto para el OLS; no es una propiedad exacta del AIPW.
Cotas de Manski	ATE [−37,66; 48,48]; ancho 86,13	Sin ignorabilidad condicional, el ATE no queda identificado puntualmente y las cotas incluyen cero. Se usa el rango observado de `Y`, [10,41; 96,54], como ilustración: los extremos muestrales no garantizan el soporte poblacional. Requieren consistencia/SUTVA y resultado acotado.
Placebo de tratamiento permutado — **pasa**	p = 0,005; percentil 100	200 réplicas, pliegues fijos. Placebo: media −0,04, DE 0,62, IC [−1,42; 1,06]. El ATE observado (5,16) es extremo. Evalúa calibración e implementación; no prueba ignorabilidad.
Placebo de resultado permutado — **pasa**	0,04; IC [−0,23; 0,32]	Se permutó `momage` y se usó como pseudo--resultado, manteniendo `X` original. El umbral material es 0,10. No prueba ausencia de confusión; es un diagnóstico de calibración.

Acción de la puerta. Si el placebo de tratamiento falla o el placebo de resultado es material: `revisar_identificacion`. Si el soporte se rompe: `abstenerse` (sin número). Si hay deriva: `reentrenar`. Si el balance ponderado o la estabilidad del efecto se deterioran: `alertar`. Si todo está dentro de umbral: `continuar`.

6. Estimación, diagnósticos y resultados

Estimador principal: **AIPW con cross-fitting** $K = 5$, semilla 4242. Los nuisances se ajustan fuera del pliegue que predicen. El OLS con las 25 covariables es el comparador.

Cantidad	**`synthetic/ihdp`**
Diferencia cruda	10,3 puntos; IC aprox. [7,60; 13,05]
ATE OLS (comparador)	4,8 puntos; IC [3,8; 5,8]
ATE AIPW	**5,2 puntos; IC [3,9; 6,4]**
ESS de Kish OOF / n	332,2076 / 448 = 0,7415 (≈332/448 y 0,74)
Rango de propensión OOF, antes de `trimming`	[0,043; 0,916]
Solape OOF en [0,05; 0,95], antes de `trimming`	0,99777 (≈99,8 %; la CLI redondea 100 %)
Unidades recortadas	1/448 (0,2232 %): la recortada es control (0,3891 % de controles); 0 tratadas
SMD máximo sin ponderar	0,43
SMD máximo ponderado por IPW OOF	0,11
Trampa `score_post`	−0,1; el coeficiente se vació
R^2 de la proyección individual	0,095; discriminación baja

Estabilidad entre contrastes. Se comparan la diferencia cruda (10,3; IC aprox. [7,60; 13,05]), OLS (4,8; IC [3,8; 5,8]) y AIPW (5,2; IC [3,9; 6,4]). Es una comprobación de estabilidad entre estimadores —en particular, de los dos ajustados—, no una prueba de identificación ni de ignorabilidad.

Cobertura Monte Carlo. En un DGP ilustrativo propio —no IHDP ni Jobs—, con $n = 500$, $R = 100$ y semilla `20261111`, la cobertura de los IC al 95 % fue: AIPW 0,97 (error MC 0,01706), OLS 0,96 (error MC 0,01960) e ingenuo 0,00 (error MC 0). AIPW difiere 0,02 del nominal y queda fuera de ±1 error MC: esta corrida no sustenta una afirmación de calibración exacta.

Validación por particiones. El estimando primario es el de `train`. Las otras particiones son un chequeo de estabilidad, no un holdout aleatorizado ni una prueba de ignorabilidad:

Partición	**n**	**ATE AIPW**	**IC 95 %**
train	448	5,16	[3,93; 6,38]
validation	149	1,93	[−2,45; 6,31]
test	150	1,63	[−3,91; 7,18]

Los ATE de `validation` y `test` son más bajos y sus intervalos son anchos; los IC se solapan con el de `train`, pero la evidencia no confirma una estabilidad precisa. Se reporta así, sin ocultar la diferencia.

Estratos predeclarados. El corte es `bw` en la mediana de `train`, declarado antes de mirar los efectos:

Estrato	**n**	**Efecto**	**IC 95 %**
`bw` alto (> mediana)	224	7,2	[5,5; 8,8]
`bw` bajo (≤ mediana)	224	3,2	[1,4; 4,9]

No es un CATE: son dos medias de scores AIPW con su IC. El corte no se eligió por ganancia de varianza.

Diagnósticos. Las propensiones de `train` son predicciones fuera de pliegue (OOF), no de un ajuste en toda la muestra. Rango, ESS, solape y SMD se evalúan antes del `trimming`; la fila de recortes resume su aplicación. El SMD sin ponderar es el máximo entre tratados y controles; el SMD ponderado usa pesos IPW OOF y es el que usa la puerta. Ningún diagnóstico demuestra que los supuestos causales se cumplan.

7. Servicio, tarjeta y registro

Contrato del servicio. El servicio carga el bundle campeón y no lee CSV ni `interventions.json`.

Ruta	Respuesta
`/efecto`	ATE, IC, versión, `estado_puerta`, criterio de identificación (`backdoor: pasa`), E-value, valor de robustez, cotas de Manski, placebos con `pasa/falla`, integridad y limitaciones; si la puerta es `falla` o el bundle no verifica, abstención sin número.
`/consulta`	media del estrato con IC, `estado_puerta`, E-value del estrato y referencia al placebo poblacional; fuera de soporte, abstención sin número.
`/heterogeneidad`	Devuelve `proyeccion`, una proyección lineal del score AIPW, con IC condicional y advertencias. No es un CATE identificado; `sensibilidad.aplicable = false` y `placebo.aplicable = false`; fuera de soporte, abstención.
`/efecto_individual`	Alias deprecado de `/heterogeneidad`, con el mismo contrato (`proyeccion`, IC condicional y advertencias), las mismas limitaciones y abstención; tampoco es un CATE identificado.
`/salud`	estado, versión, puerta, integridad y resúmenes del criterio backdoor, sensibilidad, cotas de Manski y placebos.

Tarjeta. `tarjeta.json` incluye estimando, población, supuestos, umbrales, semilla, hash del dataset, estimador, uso previsto, limitaciones, soporte, puerta, sensibilidad, placebo, identificación, validación por particiones y versión de esquema. Clasifica los supuestos como `observable` o `no_observable`.

Registro. Cada corrida crea `artifacts/registro/vNNNN/` con `estimacion.json`, `tarjeta.json` y `manifest.json` con hashes. El alias `artifacts/alias_champion.json` apunta a la versión campeona y `artifacts/registro/champion` se mantiene por compatibilidad. Una versión con puerta `falla` nunca se promueve; una versión en `alerta` exige aceptación explícita. `v0001` a `v0007` se conservan intactos; el champion actual es `v0008`. El servicio verifica alias y hashes al cargar.

8. Monitoreo y regla de decisión

Cinco acciones, en orden de severidad: `abstenerse` > `revisar_identificacion` > `reentrenar` > `alertar` > `continuar`. La tabla de la rúbrica las lista de menor a mayor severidad; la puerta aplica primero la más severa.

Acción	Cuándo y qué hace el servicio
`continuar`	todo dentro de umbral; `estado_puerta = pasa`.
`alertar`	balance ponderado o estabilidad del efecto; responde con número y advertencia (`estado_puerta = alerta`).
`reentrenar`	PSI de covariables sobre umbral; responde con advertencia (`estado_puerta = reentrenar`).
`revisar_identificacion`	placebo o control negativo falla; responde con advertencia (`estado_puerta = revisar_identificacion`).
`abstenerse`	soporte insuficiente o tratamiento constante; no devuelve número (`estado_puerta = falla`).

Ventanas de la corrida (`synthetic/ihdp`). La ventana de producción es `sana`; las demás son evidencias de estrés y no bloquean el servicio por sí solas.

Ventana	PSI máx	SMD pond.	ATE ventana	Acción
`sana`	0,024	0,07	5,64	`continuar` / `pasa`
`deriva`	0,883	0,03	5,16	`reentrenar`

Ventana	PSI máx	SMD pond.	ATE ventana	Acción
positividad	3,069	5,16	7,2	abstenerse / falla
balance	0,029	0,05	3,63	alertar
confusor_oculto	0,0	0,03	1,0	alertar

La ventana sana tiene ATE 5,64 frente al campeón 5,16 y una diferencia de 0,49, por debajo del umbral de 1,25: continuar. La ventana de positividad rompe el solapamiento (0 %) y obliga a abstenerse. La ventana de balance y la de confusor oculto se detectan por estabilidad del efecto (diferencias 1,52 y 4,16), no por el SMD ponderado. El confusor oculto es un **stress test**: el monitor no observa U; la sensibilidad de la sección 5 es la que acota su fuerza.

Umbrales. smd_max = 0,50, smd_ponderado_max = 0,25, psi_alerta = 0,25, solape_min = 0,30, efecto_estabilidad = 0,20. Son convenciones iniciales, no leyes universales; están en la tarjeta y se declaran como tales.

Sensibilidad de umbrales ±20 %. Ya está incluida en esta corrida: se observaron 0 cambios de acción respecto de la clasificación base. Es una comprobación local de esta ejecución, no una calibración universal.

9. Flujo del trabajo

La figura de la página 1 resume la cadena completa. Cada etapa consume los artefactos de la anterior, sin saltos:

- observed_train.csv: datos observados con hash y particiones.
- datos.py: roles de las columnas, verificación de hashes y la pared.
- estimacion.py: AIPW con cross-fitting, IC, diagnósticos, sensibilidad y placebo.
- registro.py: tarjeta, versión inmutable y alias del campeón.
- monitor.py: ventanas de vigilancia y puerta de decisión (sección 8).
- servicio.py: FastAPI con el bundle del campeón en memoria.

El estado de la puerta y la regla de abstención están en la sección 8.

10. Evidencia y reproducibilidad

Desde la raíz del repositorio:

```
SIC_ESCENARIO=synthetic/ihdp make PYTHON=.venv_ci/bin/python demo
SIC_ESCENARIO=synthetic/ihdp make PYTHON=.venv_ci/bin/python pruebas
make PYTHON=.venv_ci/bin/python evidencia
shasum -a 256 -c evidencia/SHA256SUMS
```

Cifra	Evidencia
ATE 5,2 [3,9; 6,4]	evidencia/02_estimacion.txt
Comparación: cruda 10,3 [7,60; 13,05] (aprox.); OLS 4,8 [3,8; 5,8]; AIPW 5,2 [3,9; 6,4]	evidencia/02_estimacion.txt
E-value 2,07 / RV 37,4 % / Manski [−37,66; 48,48]	evidencia/03_sensibilidad.txt
Placebo D p=0,005; placebo Y 0,04 [−0,23; 0,32]	evidencia/04_placebo.txt
OOF antes de trimming: e [0,043; 0,916]; solape 0,99777 (≈99,8 %); ESS 332,2076/448 = 0,7415; SMD ponderado 0,11; 1 recorte (0,2232 %), control	evidencia/02_estimacion.txt
Cobertura MC en DGP propio: AIPW 0,97; OLS 0,96; ingenuo 0,00	evidencia/10_cobertura.txt y evidencia/10_cobertura.json
Puerta de producción y ventanas	evidencia/05_puerta.txt
Sensibilidad de umbrales ±20 %: 0 cambios de acción	evidencia/05_puerta.txt

Cifra	Evidencia
Versión, manifiesto y alias	`evidencia/06_registro.txt`
Servicio y abstención	`evidencia/07_servicio.txt`
DAG	`evidencia/08_dag.txt`
Pruebas	`evidencia/09_pruebas.txt`

No hay cifras inventadas: las de este documento salen de `artifacts/estimacion.json`, `artifacts/monitor_estado.json` y `artifacts/registro/v0008/`. El champion actual es `v0008`; `v0001` a `v0007` permanecen intactos. Si se vuelve a ejecutar la cadena, se crea una versión nueva y el alias cambia; la evidencia conserva los hashes de la corrida.

11. Cierre para un lector no técnico

Decisión recomendada (en el escenario sintético). El programa muestra un efecto promedio positivo de unos **5,2 puntos** en el test cognitivo, con un intervalo de confianza de **3,9 a 6,4 puntos**. La estimación es compatible con un beneficio promedio, pero no es una garantía para un niño concreto ni para una población real.

Qué sostiene la recomendación. El resultado se apoya en un ajuste por 25 covariables observadas, un buen solapamiento entre tratados y controles, un placebo de tratamiento que se comporta como se espera y un placebo de resultado sin efecto material. La sensibilidad indica que un confusor no medido tendría que ser moderadamente fuerte (RR aproximada ≥ 2,07) para explicar el efecto. Las cotas de Manski incluyen cero: sin ignorabilidad no basta para afirmar un efecto positivo.

Cuándo dejar de confiar. Si la población cambia y el monitor detecta deriva (`reentrenar`); si el solapamiento se rompe (`abstenerse`); si el placebo o el control negativo fallan (`revisar_identificacion`); si la validación en otras particiones sigue mostrando estimaciones muy distintas; o si el coste o el riesgo de la intervención exige un efecto mayor que el que el IC permite descartar.

Lo que este cierre no dice. No dice que el programa funcione en niños reales, no reemplaza un ensayo aleatorizado y no autoriza decisiones clínicas, laborales o de política pública. Es una demostración metodológica sobre datos sintéticos.

12. Reutilización y decisiones propias

Reutilización. Se reutilizan el estimador AIPW con cross-fitting, el esquema de tarjeta, la puerta, el registro con manifiesto y el monitor del prototipo abierto. Se adaptan las 25 covariables, el corte `bw`, los umbrales, las ventanas y la capa de sensibilidad/placebo.

Herramientas externas. Las cifras reproducibles provienen de la ejecución local y de los comandos de §10 con sus salidas en `evidencia/`. Este cierre y `BITACORA.md` pueden editarse con apoyo de asistentes de texto; ese apoyo no sustituye el cómputo ni los hashes de evidencia.

Decisiones propias.

- Corte de heterogeneidad en `bw` en la mediana de `train`: el bajo peso al nacer define la población clínica del IHDP; se declara antes de mirar los efectos y no se elige por ganancia de varianza. En `jobs` el corte es `nodegree`.
- Umbrales recalibrados para `ihdp`: `smd_max = 0,50`, `smd_ponderado_max = 0,25`, `psi_alerta = 0,25`, `solape_min = 0,30`, `efecto_estabilidad = 0,20`. Son convenciones iniciales, documentadas.
- Ventanas de estrés: deriva de `bw` en +1 DE, positividad sobre `bw`, balance sobre `momage` y confusor oculto simulado. En `jobs`: `age`, `re74`, `educ`.
- Sensibilidad y placebo: E-value + valor de robustez y placebo de tratamiento + placebo de resultado, porque el resultado es continuo y ninguna medida individual es exacta para el AIPW.

El caso sigue siendo guiado; por eso 1.1 queda en parcial.

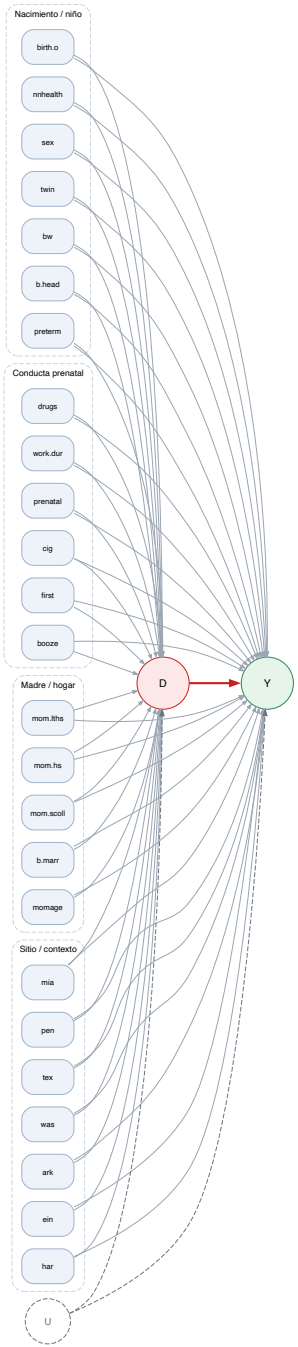
13. Defensa (15 minutos)

10 minutos de exposición y 5 de preguntas. Las tres preguntas fijas, con el artefacto que se mostraría:

1. **Muestre el artefacto que justifica la abstención o el estado de la puerta.** `artifacts/monitor_estado.json` y `evidencia/05_puerta.txt`; para la abstención por soporte, `evidencia/07_servicio.txt`.
2. **Nombre un supuesto no observable y explique cómo lo acotó.** Ignorabilidad condicional; E-value 2,07 (IC 1,85) y valor de robustez OLS 37,4 %, en `evidencia/03_sensibilidad.txt`. Explicar que no es una prueba.
3. **¿Qué cambio mínimo haría que dejara de recomendar la intervención?** Un confusor no medido con asociación aproximada menor que 2,07; un fallo del placebo o del control negativo; una ruptura de solapamiento; o una deriva que el monitor clasifique como `reentrenar` o `abstenerse`.

Si no se puede mostrar el artefacto o reproducir la cifra, ese resultado no cuenta como evidencia propia.

14. DAG completo de `synthetic/ihdp`



DAG (`dag_ihdp_detalle.svg`): un nodo por covariable pre-tratamiento (25), tratamiento `D` y resultado `Y`; aristas según el benchmark. `U` es una amenaza hipotética de confusión no medida, no una variable documentada en el DGP del benchmark.

Grupos de covariables. Nacimiento / niño: `bw`, `b.head`, `preterm`, `birth.o`, `nnhealth`, `sex`, `twin`. Conducta prenatal: `cig`, `first`, `booze`, `drugs`, `work.dur`, `prenatal`. Madre / hogar: `momage`, `mom.lths`, `mom.hs`, `mom.scoll`, `b.marr`. Sitio / contexto: `ark`, `ein`, `har`, `mia`, `pen`, `tex`, `was`.

La versión resumida (plate), con covariables agrupadas, está en `figuras/dag_ihdp_plate.svg`. La versión de `synthetic/jobs`, con 8 covariables, está en `figuras/dag_jobs.svg`.

15. Rúbrica: estado del prototipo

ID	Subcriterio	Estado	Evidencia / límite
1.1	Pregunta de decisión y estimando	Parcial	Pregunta de decisión y ATE en §2; el caso es guiado, así que no puede ser completo
1.2	Datos y autorización	Completo	§1; hashes de splits; datos sintéticos sin registros personales
2.1	Estrategia de identificación	Completo	§3: backdoor por observables; por qué no IV/DiD/RD
2.2	Supuestos clasificados	Completo	§4: `observable` / `no_observable` en tarjeta; evidencia falsificable §5–§8
2.3	Estimación con intervalo y validación	Completo	§6: AIPW K=5, IC, comparación de estimadores, cobertura Monte Carlo en DGP propio y validación por particiones
2.4	Interpretación y sensibilidad	Completo	§5: E-value y RV con lectura y límites
3.1	Servicio y contrato	Completo	§7: `/heterogeneidad` con `proyeccion` e IC condicional, alias deprecado, puerta y abstención; `humo.py`
3.2	Model card completa y propia	Completo	§7; `tarjeta.json` con uso previsto, limitaciones, soporte y puerta
3.3	Registro con manifiesto	Completo	§7; champion `v0008`, `v0001`–`v0007` intactos, manifiesto y `alias_champion.json`; bloqueo de `falla` probado
4.1	Señales con umbral y acción	Completo	§8: PSI, SMD ponderado, ESS, solape y estabilidad; umbrales declarados y sensibilidad local ±20 %
4.2	Regla de decisión probada	Completo	§8: cinco acciones y cinco ventanas contrastantes
4.3	Control negativo o placebo	Completo	§5: placebo de tratamiento y placebo de resultado con lectura
4.4	Supuesto no observable	Completo	§4–§5: ignorabilidad declarada y acotada con E-value/RV
5.1	Cadena coherente	Completo	§9–§10: datos, estimación, puerta, tarjeta, registro y servicio
5.2	Paquete de evidencia	Completo	`evidencia/` con comando, salida y hash por cifra
5.3	Reutilización de lo propio	Completo	§12: qué se reutiliza y qué se adapta
6.1	Decisiones propias	Completo	§12: corte `bw`, umbrales, ventanas y elección de sensibilidad
6.2	Defensa en vivo	Completo	§13: guion de 15 min y tres preguntas fijas
6.3	Documento de cierre	Completo	§11: decisión, efecto, supuestos y cuándo dejar de confiar

Lectura. El prototipo cubre los contratos técnicos y la evidencia. La meta realista es **19,5 / 20**: 1.1 queda en parcial porque el caso es guiado. No se declara completo ningún subcriterio sin evidencia en `evidencia/`. La rúbrica sigue siendo una guía; la nota final la asigna una persona.